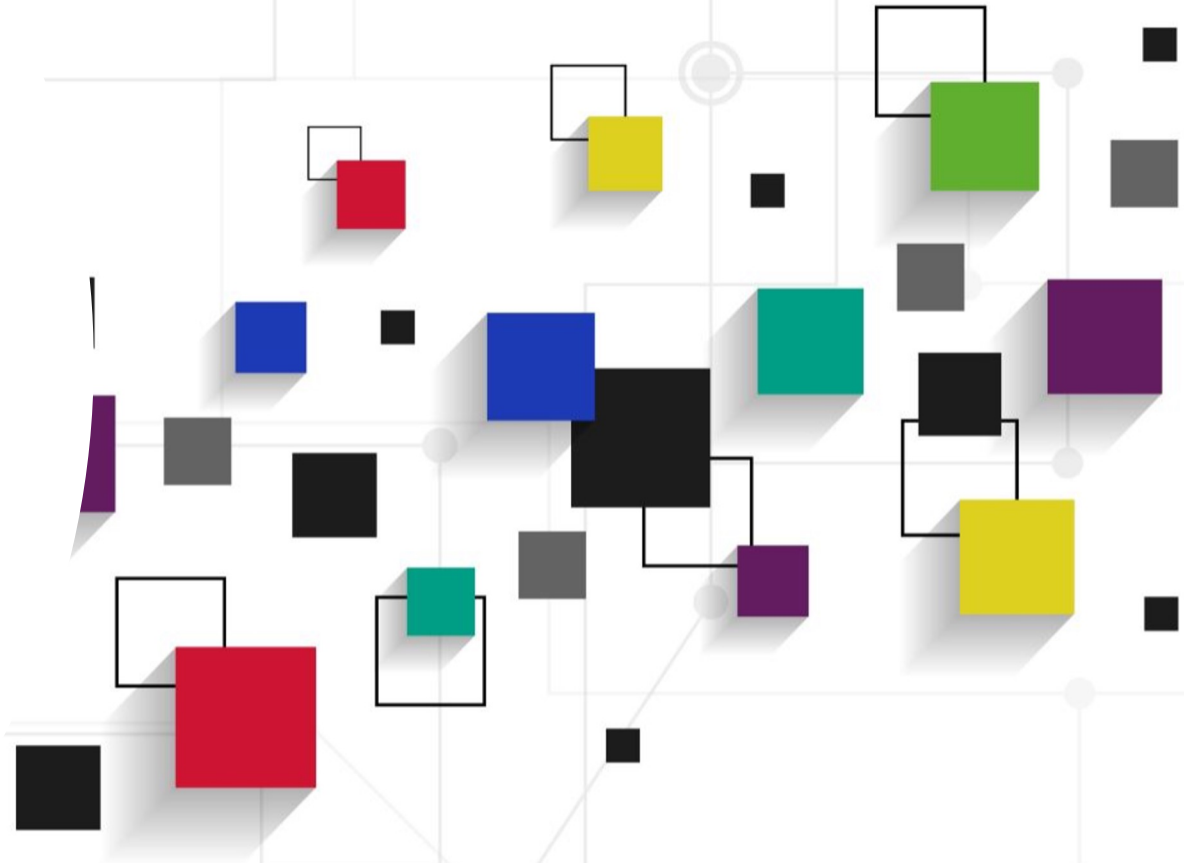
Data Tidak Terstruktur

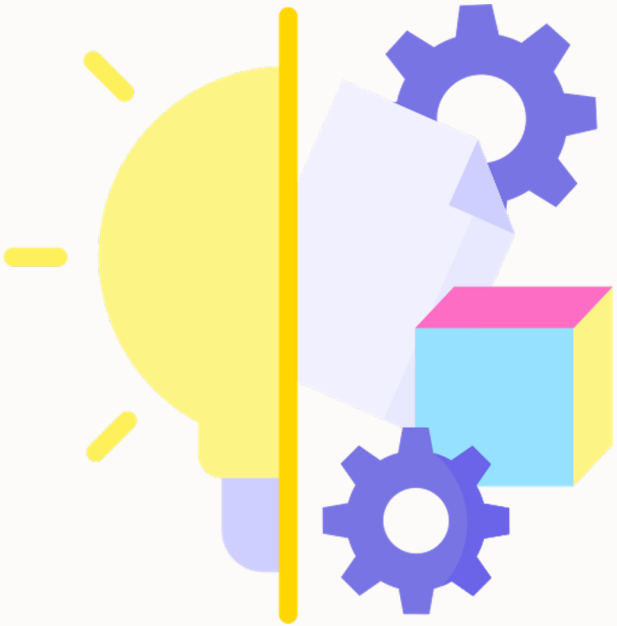
Pertemuan 13 - Teknologi Perekayasaan Data

Politeknik Statistika STIS

Siti Mariyah, Ph.D

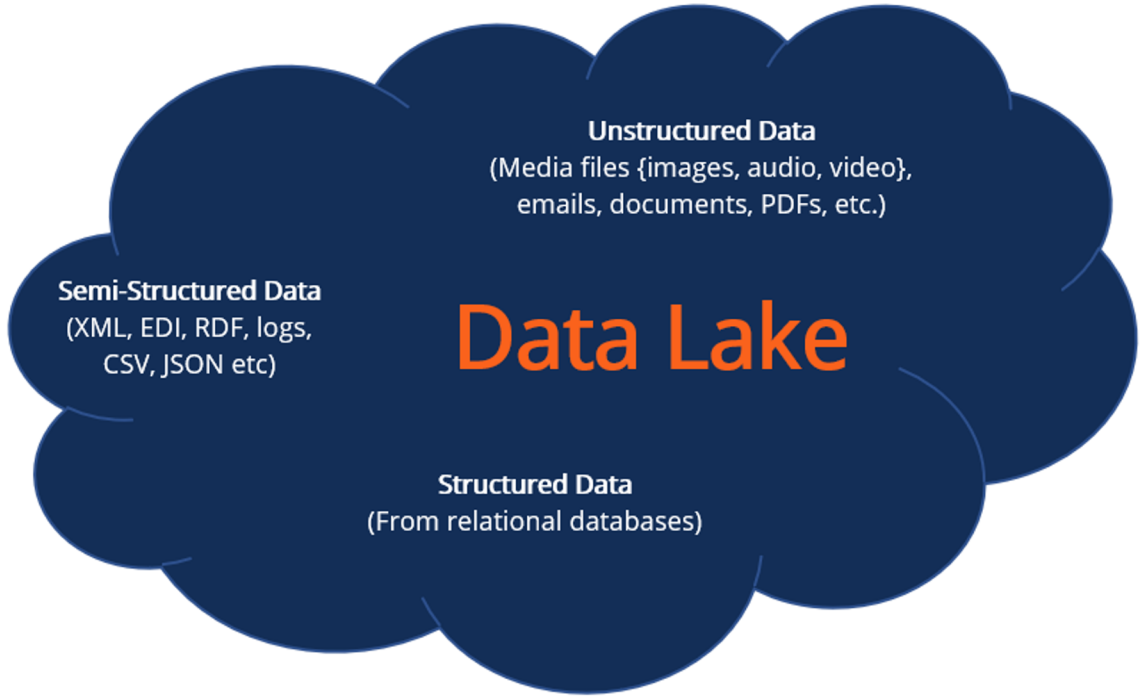


Agenda Pertemuan



1. Data Lake and Data Type Overview
2. Structuring Unstructured Data
3. Pemrosesan Semi-structured Data
4. Pemrosesan Unstructured Data
5. Big Data di BPS

Sekilas Data Lake



- Menyimpan berbagai data dengan tipe data yang beragam
- Bersifat *schema on read:* skema dibuat ketika data di-read, bukan sebelum data disimpan
- Fleksibilitas untuk memodifikasi struktur data (*unstructured* ke *structured* atau sebaliknya)

Jenis Tipe Data

- **Structured data** – data yang dapat dianalisis secara efektif. Data diatur ke dalam repositori terformat yang biasanya berupa database. Semua data disimpan di database SQL dalam tabel dengan baris dan kolom, serta memiliki kunci relasional. Data terstruktur adalah jenis data yang paling banyak diproses oleh organisasi dan cara paling sederhana untuk mengelola informasi.

  Contoh : Relational data

- **Semi-Structured data** – informasi yang tidak berada dalam database relasional tetapi memiliki beberapa properti organisasi yang membuatnya lebih mudah untuk dianalisis. Dengan beberapa proses, data dapat disimpan dalam basis data relasi.

  Contoh: XML data, JSON data

- **Unstructured data** – data yang tidak diatur dengan cara yang telah ditentukan atau tidak memiliki model data yang telah ditentukan.

  Contoh: Word, PDF, Teks, Medialog

Structured vs Semi-structured vs Unstructured

Rincian	Structured	Semi-structured	Unstructured
Technology	It is based on Relational database table	It is based on XML/RDF(Resource Description Framework)	It is based on character and binary data
Transaction Management	Matured transaction and various concurrency techniques	Transaction is adapted from DBMS not matured	No transaction management and no concurrency
Version Management	Versioning over tuples, row, tables	Versioning over tuples or graph is possible	Versioned as a whole
Flexibility	It is schema dependent and less flexible	It is more flexible than structured data but less flexible than unstructured data	It is more flexible and there is absence of schema

Structured vs Semi-structured vs Unstructured

Rincian	Structured	Semi-structured	Unstructured
Scalability	It is very difficult to scale DB schema	It's scaling is simpler than structured data	It is more scalable
Robustness	Very robust	New technology, not very spread	
Query Performance	Structured query allow complex joining	Queries over anonymous nodes are possible	Only textual queries are possible

Apa yang Sudah Dipelajari?

Data Type

- Structured Data
- Semi-structured Data
- Unstructured Data

Processing Tools

- Hive
- HBase
- Pig
- Spark

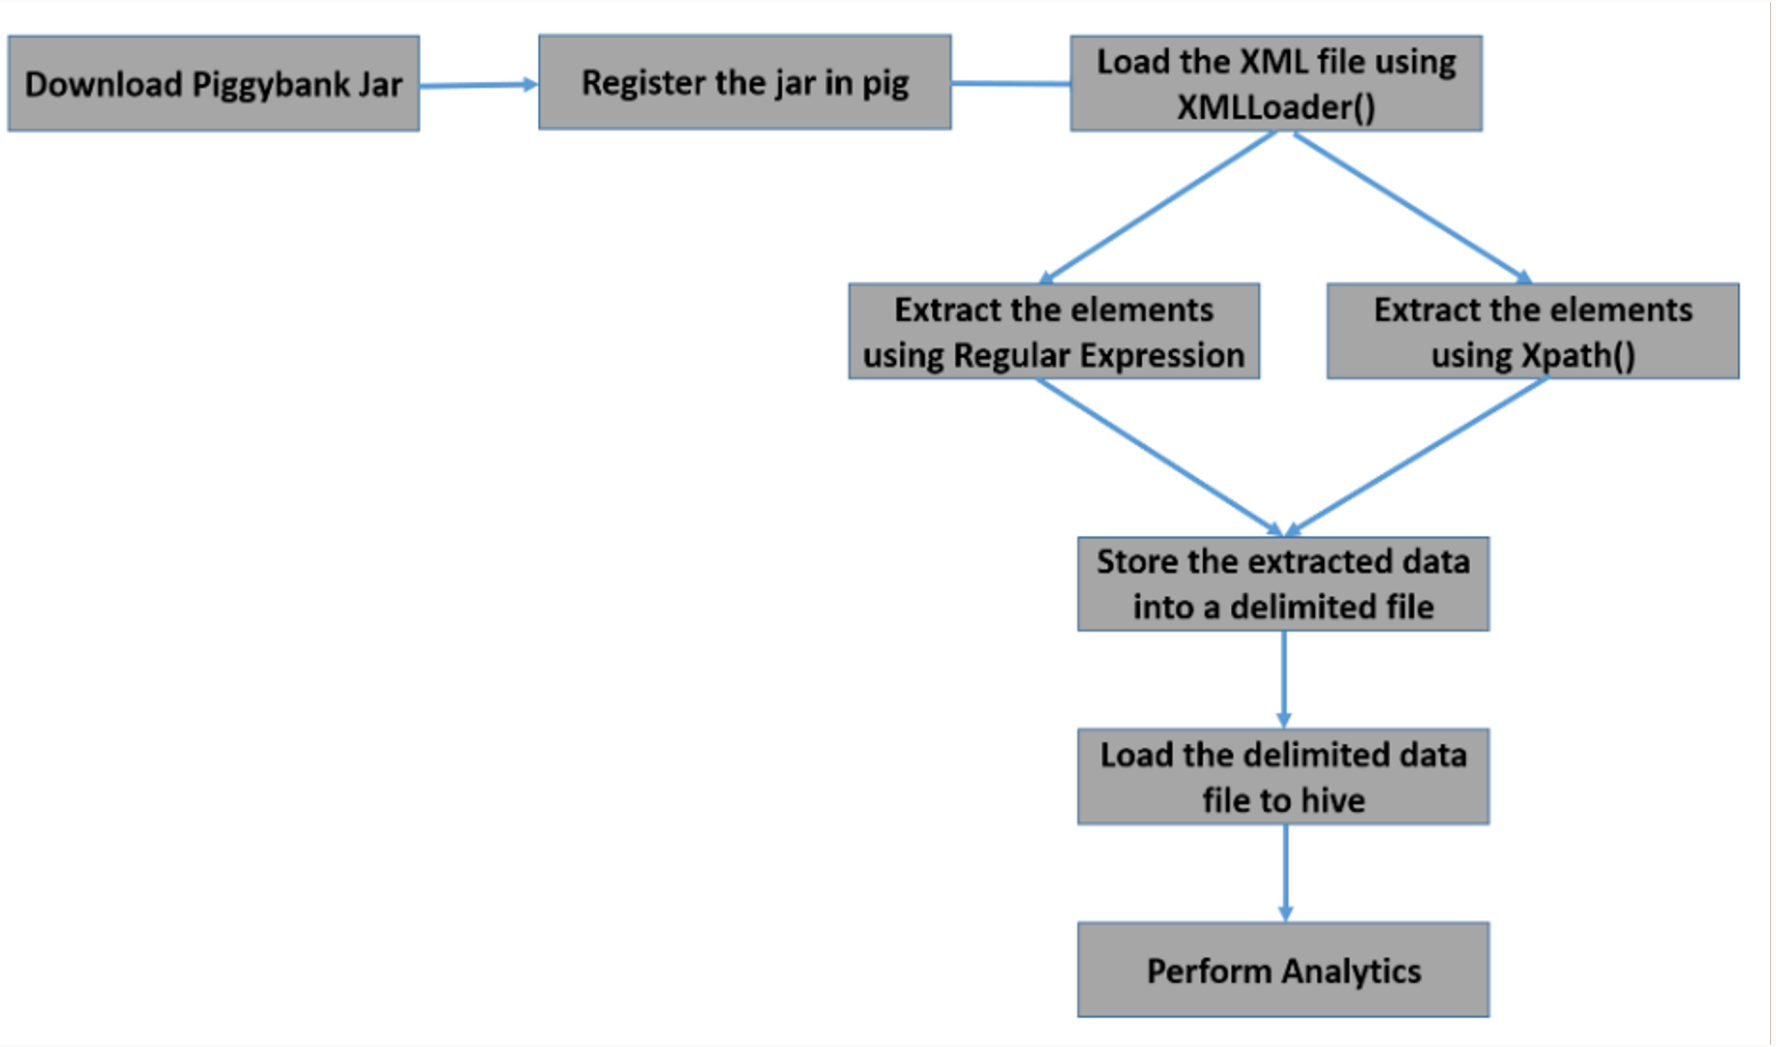
Petakan antara tipe data dengan processing tools yang dapat digunakan!

Pemrosesan Semi-Structured Data dalam Hadoop

Untuk pemrosesan data semi-structured, terdapat beberapa cara yang dapat dilakukan:

1. Melakukan konversi data ke format data Avro sehingga dapat menyediakan cara yang efisien untuk menyimpan dan memproses data.
   - Saat format data Avro disimpan, schema disimpan bersamaan dengan datanya, sehingga file dapat diproses nanti oleh program apa pun.
   - Jika program yang read data mengharapkan schema yang berbeda, maka dapat dengan mudah diselesaikan, karena kedua schema tersebut ada.
2. Menggunakan library yang dirancang untuk pemrosesan XML atau JSON files. Contohnya, XMLLoader pada Piggybank library untuk Pig. Untuk format JSON, dapat menggunakan LzoJsonInputFormat dari Elephant Bird Project.

Pemrosesan Semi-Structured Data



Contoh Transformasi

```
<?xml version="1.0"?>
<feed>
<link href="/v1/espi_third_party_batch_feed" rel="self">
<title type="text">Zip Code 93308-6173</title>
<IntervalReading>
<cost>1510</cost>
<timePeriod>
<duration>900</duration>
<start>1301889600</start>
</timePeriod>
<value>102</value>
</IntervalReading>
<IntervalReading>
<cost>1510</cost>
<timePeriod>
<duration>900</duration>
<start>1301890500</start>
</timePeriod>
<value>102</value>
</IntervalReading>
</feed>
```

```
(Zip Code 93308-6173,2011-04-04 12:00:00,2011-04-04 12:15:00,102,1510,14.803922)
(Zip Code 93308-6173,2011-04-04 12:15:00,2011-04-04 12:30:00,102,1510,14.803922)
(Zip Code 93308-6173,2011-04-04 12:30:00,2011-04-04 12:45:00,123,1812,14.731708)
(Zip Code 93308-6173,2011-04-04 12:45:00,2011-04-04 01:00:00,123,1812,14.731708)
(Zip Code 93308-6173,2011-04-04 01:00:00,2011-04-04 01:15:00,102,1510,14.803922)
(Zip Code 93308-6173,2011-04-04 01:15:00,2011-04-04 01:30:00,164,2416,14.731708)
(Zip Code 93308-6173,2011-04-04 01:30:00,2011-04-04 01:45:00,102,1510,14.803922)
(Zip Code 93308-6173,2011-04-04 01:45:00,2011-04-04 02:00:00,123,1812,14.731708)
grunt>
```

Structuring Unstructured Data (Text)

Tahapan yang biasanya dilakukan saat pemrosesan Text:

- **Text Extraction** – Proses mengambil teks mentah dari berbagai sumber, seperti dokumen teks, situs web, atau sumber data lainnya
- **Parsing/Tokenization** – Pemisahan teks menjadi unit yang lebih kecil, yang disebut token atau kata. Biasanya, teks dipisahkan berdasarkan spasi atau tanda baca untuk membentuk token-token yang dapat dianalisis lebih lanjut.
- **Phrase Recognition (Corpus Building)** – Pengenalan frasa-frasa yang lebih besar atau entitas linguistik yang memiliki makna spesifik, seperti frasa kata kerja benda, frasa nama orang, frasa keterangan waktu, dan sebagainya. Pengenalan frasa ini membantu dalam memahami konteks dan relasi antar kata-kata dalam teks.
- **Named Entity Recognition** – Pengenalan dan klasifikasi entitas tertentu dalam teks

Implementasi Nyata: Text Processing

Contoh tools dan penerapan nyata pada tiap tahapan pemrosesan teks:

- **Text Extraction** – Apache Tika dan BeautifulSoup untuk mengambil teks dari PDF, halaman web, atau dokumen kantor
- **Tokenization** – NLTK dan spaCy untuk memecah kalimat menjadi kata atau token yang siap dianalisis
- **Phrase Recognition** – spaCy (noun chunks) dan Gensim Phrases untuk mengenali frasa dan kombinasi kata bermakna
- **Named Entity Recognition** – spaCy (model en_core_web_sm) dan Stanford NER untuk mendeteksi nama, lokasi, tanggal, dan nilai numerik dalam teks
- **Contoh penerapan** – mengekstrak nama komoditas, lokasi, dan harga dari komentar publik di media sosial untuk mendukung pemantauan harga bahan pokok secara cepat

Pemrosesan Unstructured Data (Image)

Tahapan yang biasanya dilakukan saat pemrosesan data Images:

- **Image Preprocessing** – Mempersiapkan image sebelum pemrosesan lebih lanjut dengan tujuan meningkatkan kualitas image seperti *resizing*, *cropping*, *denoising*, atau *normalizing*
- **Object Detection** – Penggunaan algoritma untuk mendeteksi dan mengidentifikasi objek tertentu dalam image
- **Image Segmentation** – Segmentasi dapat dilakukan berdasarkan pixel, objek, warna, tekstur, atau atribut lainnya dalam image untuk memisahkan objek atau wilayah dalam gambar untuk analisis lebih lanjut
- **Feature Extraction** – Identifikasi dan ekstraksi fitur-fitur penting dari gambar. Fitur-fitur ini bisa berupa pola, tekstur, warna, atau atribut lain yang dapat digunakan untuk pengenalan pola, klasifikasi, atau analisis lebih lanjut
- **Annotation and Labeling** – Memberikan label atau anotasi kepada objek, wilayah, atau pixel dalam gambar.
- **Data Integration** – Menggabungkan data yang telah diolah dari berbagai gambar menjadi satu set data yang lebih besar dan terstruktur
- **Metadata Extraction** – Ekstraksi metadata seperti resolusi gambar, tanggal pengambilan, pengaturan kamera, lokasi, dan atribut lainnya yang memberikan konteks tambahan tentang gambar.

Implementasi Nyata: Image Processing

Contoh tools dan penerapan nyata pada tiap tahapan pemrosesan citra:

- **Image Preprocessing** – OpenCV dan Pillow untuk resizing, cropping, denoising, dan normalisasi citra
- **Object Detection** – YOLOv8 dan Faster R-CNN untuk mendeteksi dan mengidentifikasi objek pada citra
- **Image Segmentation** – Mask R-CNN dan U-Net untuk memisahkan objek atau wilayah dalam gambar secara piksel demi piksel
- **Feature Extraction** – model CNN pretrained seperti ResNet atau VGG16 untuk mengekstrak fitur visual (pola, tekstur, warna)
- **Annotation and Labeling** – CVAT dan Labelbox untuk memberi label pada dataset citra sebelum pelatihan model
- **Contoh penerapan** – mendeteksi bangunan dan lahan pertanian dari citra satelit menggunakan CNN untuk memutakhirkan peta wilayah kerja statistik

Pemrosesan Unstructured Data (Audio)

Tahapan yang biasanya dilakukan saat pemrosesan data Sound/Audio:

- **Audio Preprocessing** – Misal *resampling, normalization, denoising, filtering*, dan menghilangkan noise/atifacts yang tidak relevan dari audio signal
- **Feature Extraction** – Misal spectrograms, Mel-frequency cepstral coefficients (MFCCs), pitch, intensity, dan time-domain features
- **Segmentation** – Segmentasi dapat dilakukan berdasarkan silence detection, audio activity, speaker turns, atau interval waktu yang telah ditentukan
- **Transcription and Speech Recognition** – konversi bahasa lisan dalam data audio menjadi teks tertulis
- **Annotation and Labeling** – Identifikasi pembicara, emosi, sentimen, topik, atau anotasi lain yang spesifik untuk konten audio
- **Data Integration**
- **Metadata Extraction** – Misal tanggal perekaman, durasi, lokasi, spesifikasi perangkat perekaman, atau informasi lain

Implementasi Nyata: Audio dan Video Processing

Contoh tools dan penerapan nyata pada tiap tahapan pemrosesan audio/video:

- **Audio & Video Preprocessing** – FFmpeg untuk ekstraksi frame video dan konversi format, Librosa untuk resampling serta denoising audio
- **Feature Extraction** – Librosa (MFCC, spectrogram) untuk audio, dan OpenCV (optical flow) untuk mendeteksi gerakan pada video
- **Transcription and Speech Recognition** – OpenAI Whisper dan Google Speech-to-Text untuk mengubah rekaman suara menjadi teks
- **Segmentation and Annotation** – pyAudioAnalysis untuk deteksi jeda bicara, dan ELAN untuk pelabelan speaker maupun adegan video
- **Contoh penerapan** – transkripsi otomatis rekaman wawancara petugas sensus dengan Whisper untuk mempercepat pengolahan data kualitatif lapangan

Contoh

- OpenAI Whisper: https://openai.com/index/whisper/

Pemrosesan Unstructured Data dalam Hadoop

- Format data yang biasanya disimpan di Hadoop adalah data dalam bentuk text
- Walaupun demikian, Hadoop juga dapat menyimpan binary files, seperti image
- SequenceFile direkomendasikan untuk sebagian besar kasus penyimpanan dan pemrosesan binary files di Hadoop
- Namun, jika besaran data hasil split lebih dari 64 MB, maka menyimpan data dalam format aslinya lebih direkomendasikan

Pemrosesan Unstructured Data

Loading images into Spark Data Frame

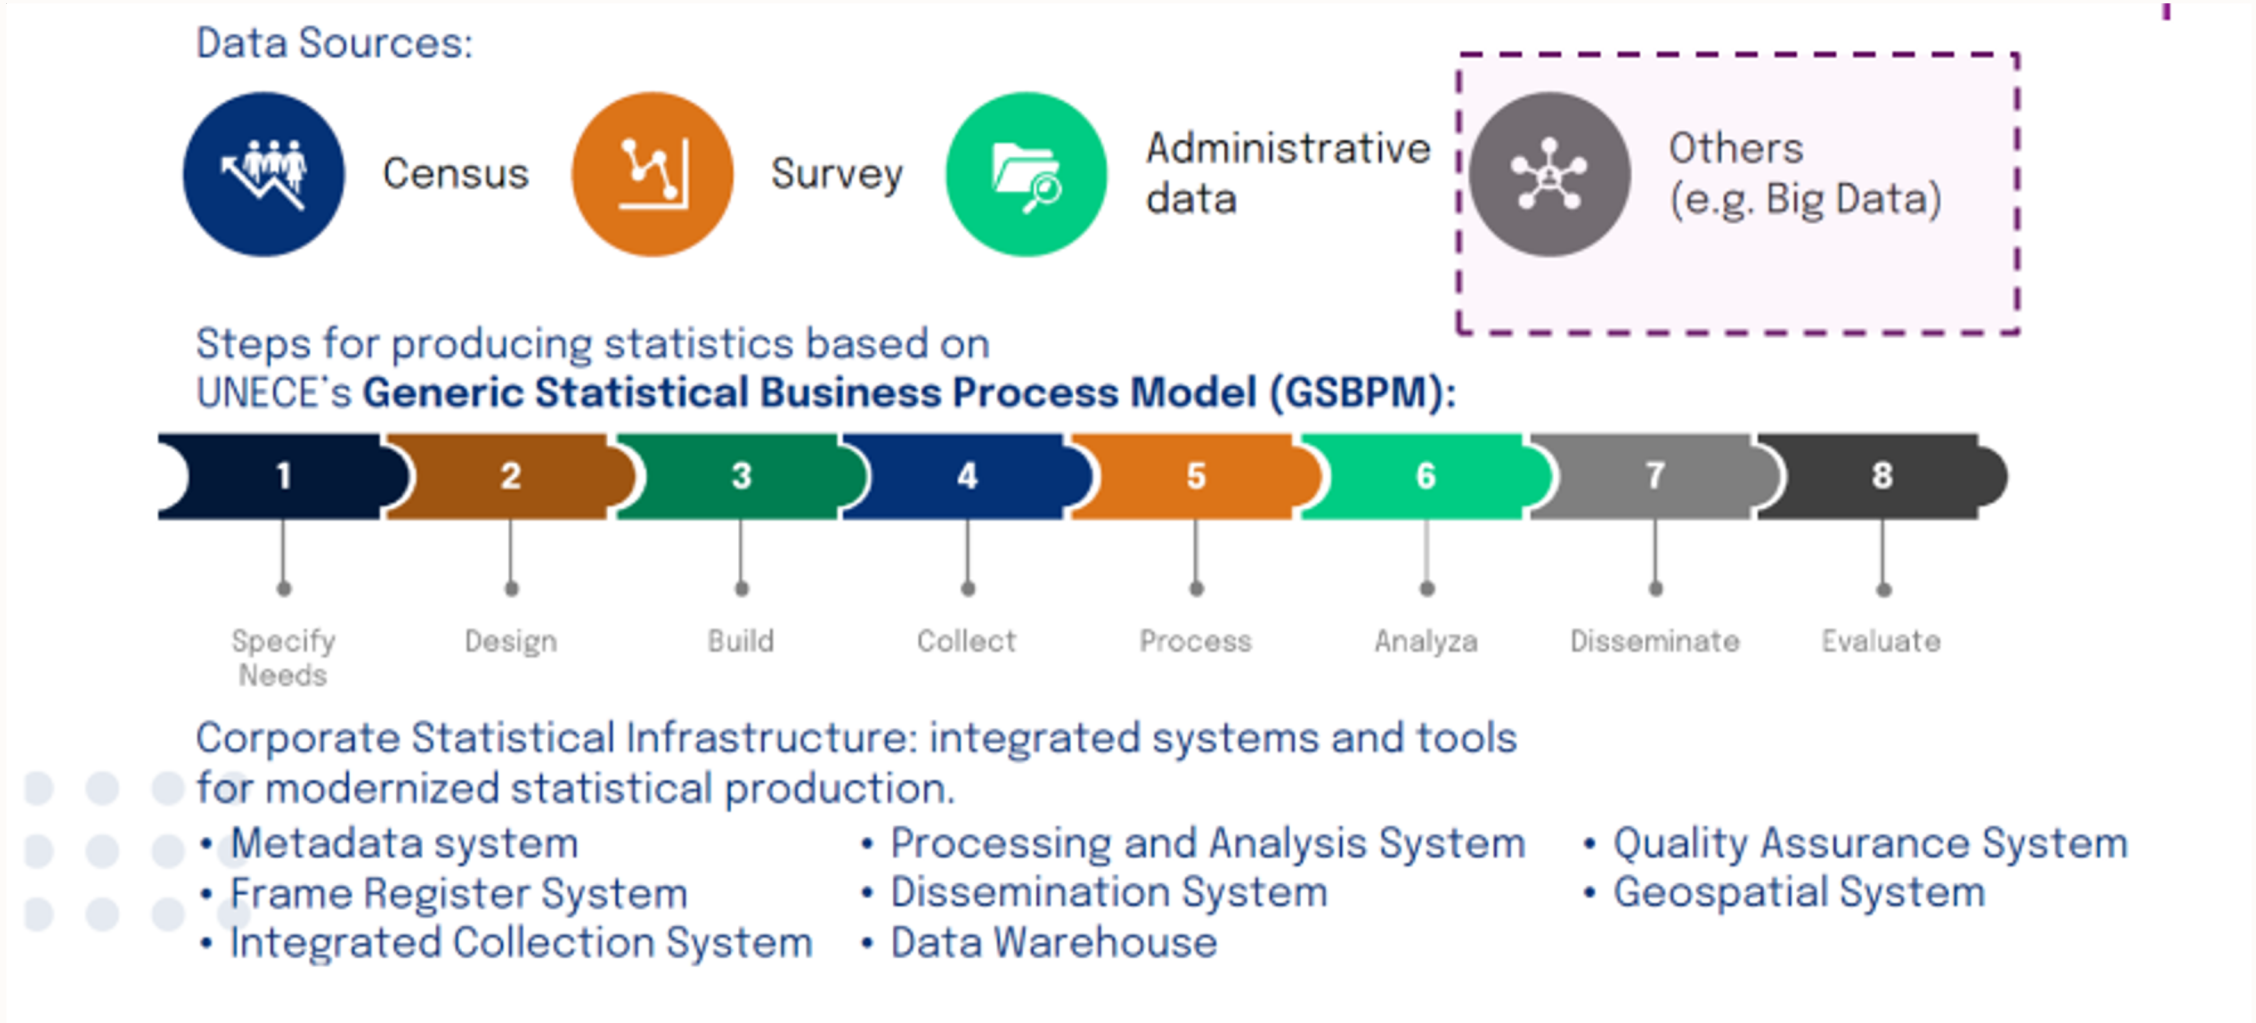
Creating the Features Data Frame

Implement Machine Learning Pipeline

- Transformation and Selection
- Train a predictive model based on these vectors and label
- Make predictions using the generated model
- Evaluate model

Big Data di BPS

Produksi Data Statistik



Beberapa Sumber 'Big' Data yang digunakan untuk *Official Statistics*



Administrative Data



Mobile Phone Data



Remote Sensing Data



AIS Data

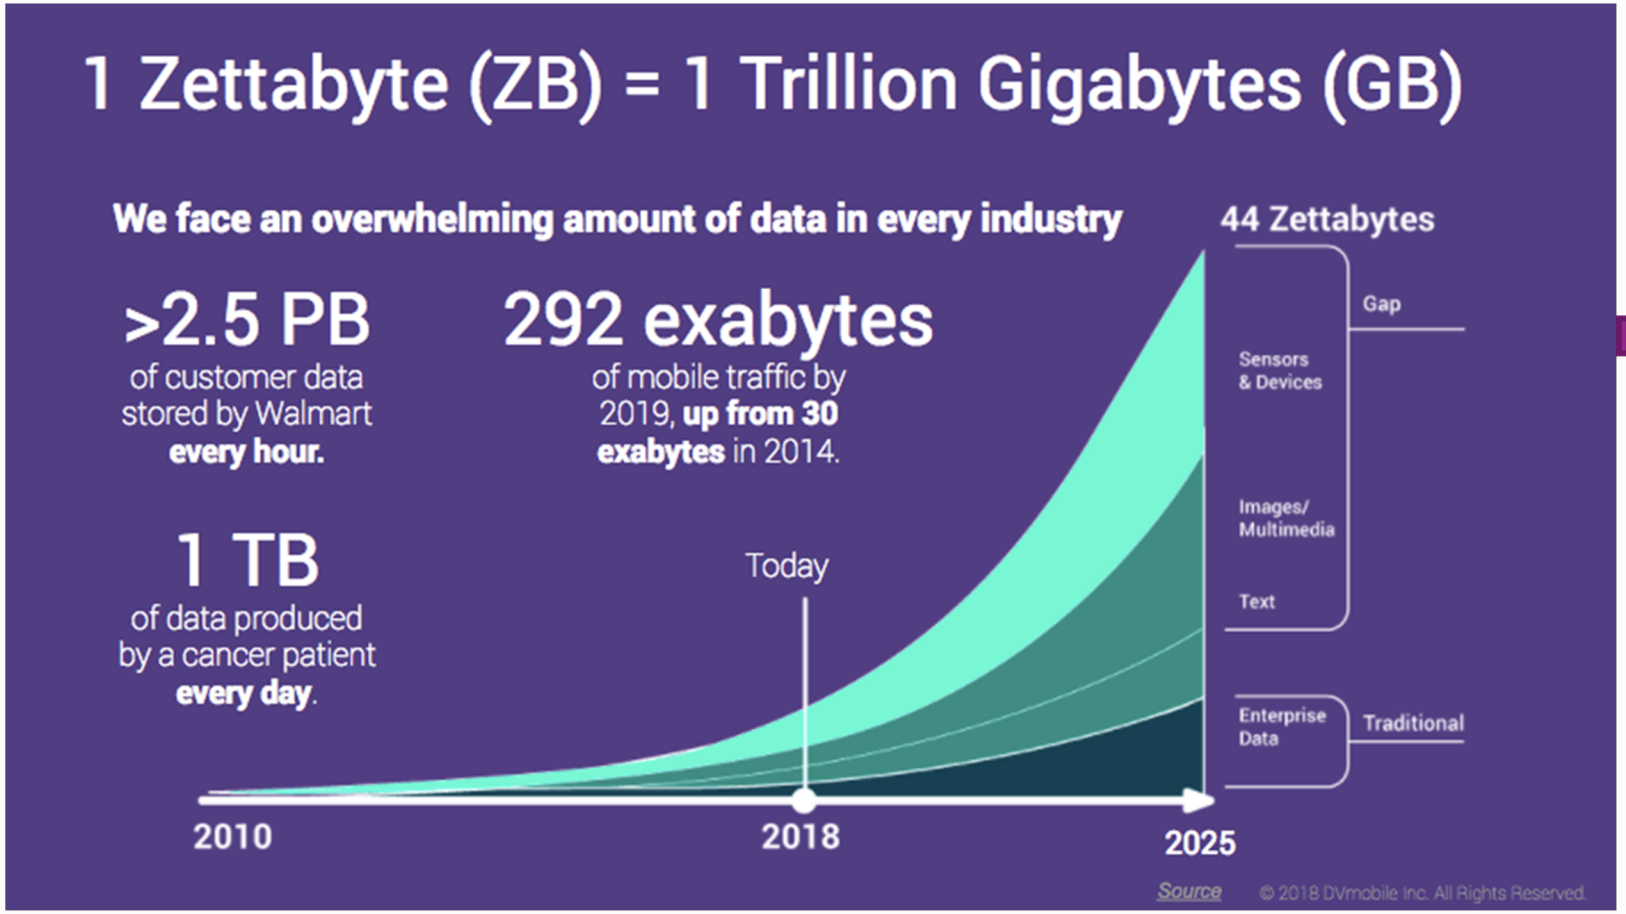


Web Scraping Data
(website,
ecommerce, dll)



Online News/
Sosial Media Data

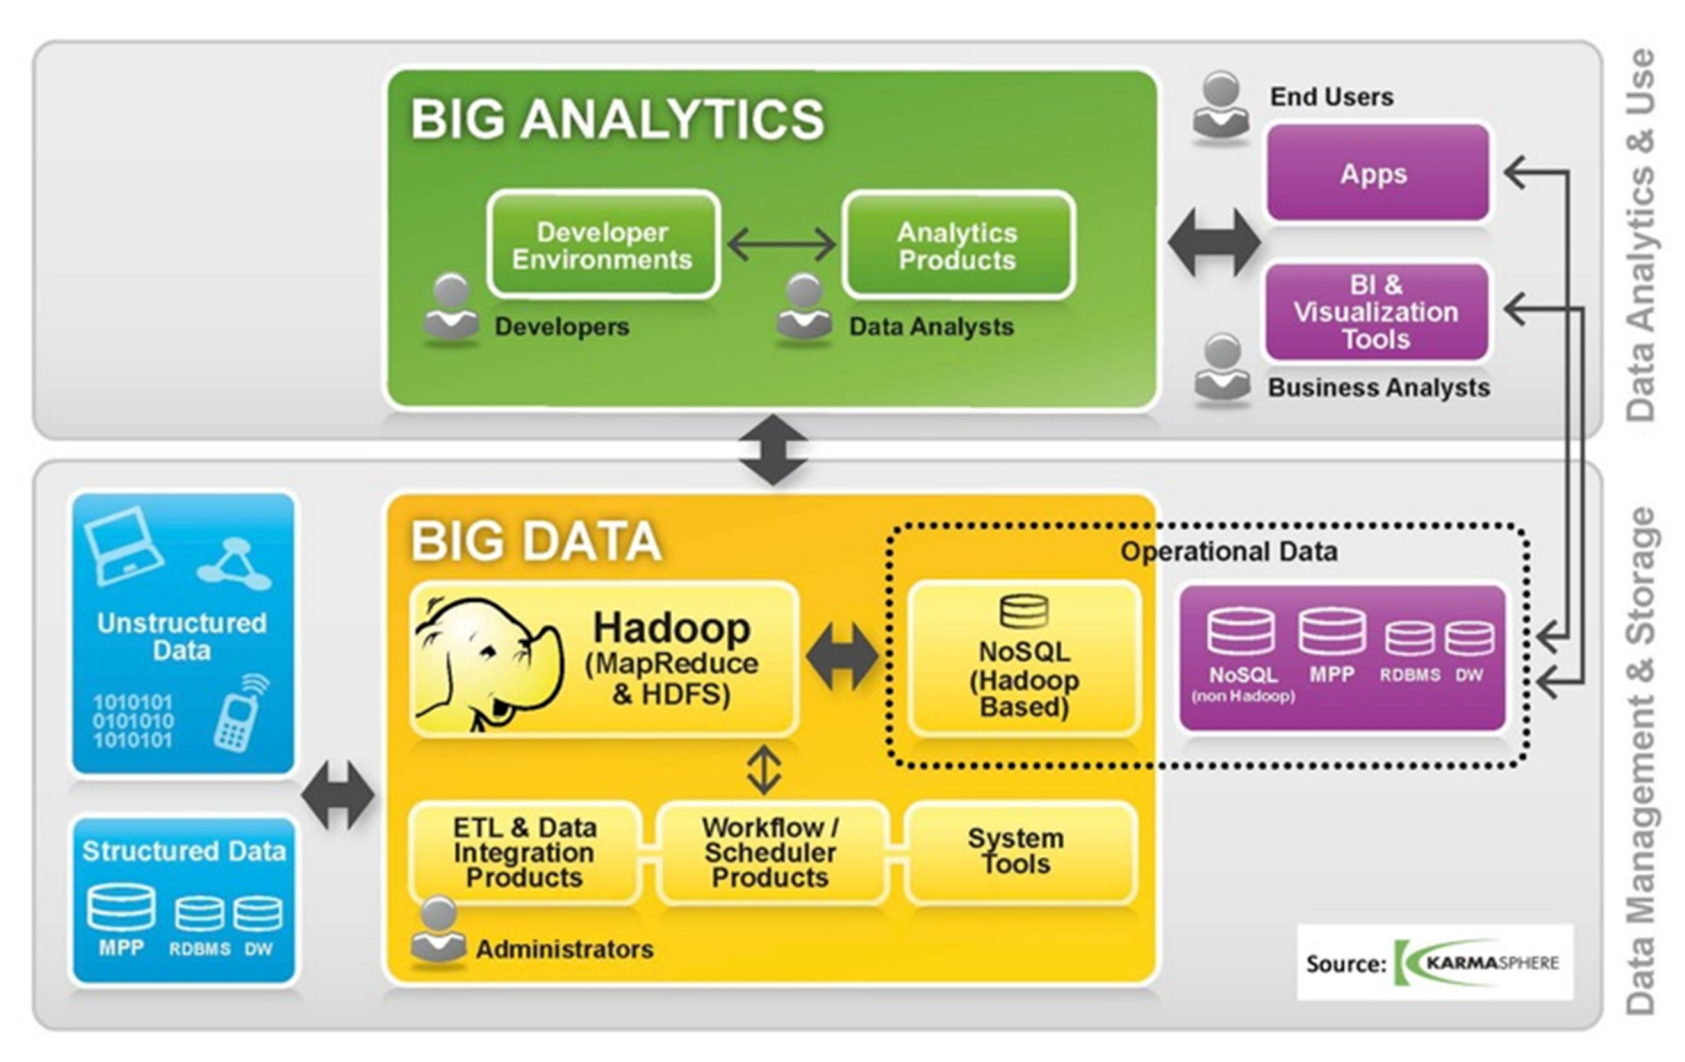
Pertumbuhan Ekponensial ‘Big’ Data



Terlihat bahwa data ‘tidak terstruktur’ tumbuh jauh lebih besar, dibandingkan data terstruktur

Sumber: https://www.gregverdino.com/everything-is-exponential/

Alur Data


BIG ANALYTICS
Developer Environments
Analytics Products
Developers
Data Analysts
End Users
Apps
BI & Visualization Tools
Business Analysts
Data Analytics & Use
Unstructured Data
1010101
0101010
1010101
Structured Data
MPP
RDBMS
DW
BIG DATA
Hadoop (MapReduce & HDFS)
ETL & Data Integration Products
Workflow / Scheduler Products
System Tools
Administrators
Operational Data
NoSQL (Hadoop Based)
NoSQL (non Hadoop)
MPP
RDBMS
DW
Source: KARMASPHERE
Data Management & Storage

Oleh-oleh


TRIBECA
FESTIVAL
2024
OFFICIAL SELECTION
THE THINKING GAME

Terima kasih