MODUL 10 – HBASE

1.1. Deskripsi Singkat

HBase adalah sebuah sistem penyimpanan data terdistribusi yang dirancang untuk menyimpan dan mengelola data terstruktur dan semi-terstruktur dalam skala besar. HBase dibangun di atas Apache Hadoop dan merupakan bagian dari ekosistem Apache Hadoop.

HBase menggunakan model data yang disebut "column-family", di mana data disimpan dalam baris dan kolom. Setiap baris dalam HBase memiliki kunci unik (*Rowkey*) yang digunakan untuk mengakses data tersebut. Kolom dalam HBase dikelompokkan dalam column family, dan setiap column family memiliki nama yang diberikan oleh pengguna.

HBase didesain untuk menyediakan akses cepat dan skalabilitas horizontal yang tinggi dimana HBase dapat menangani volume data yang sangat besar dan memberikan kinerja read/write yang tinggi. HBase juga mendukung replikasi data otomatis antara cluster, yang membuatnya toleran terhadap kegagalan.

HBase menyediakan client API yang memungkinkan aplikasi atau pengguna untuk berinteraksi dengan HBase. API ini memungkinkan akses read/write ke data di tabel HBase. Selain itu, HBase juga menyediakan shell interaktif yang memungkinkan pengguna untuk menjalankan perintah HBase menggunakan bahasa scripting.

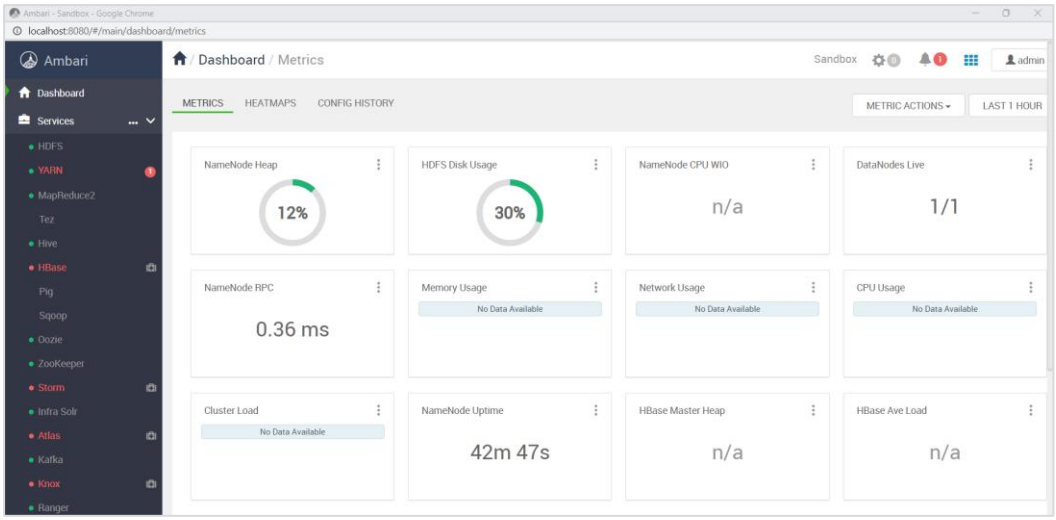
1.2. Tujuan Praktikum

Setelah praktikum pada modul 10 ini, diharapkan mahasiswa mempunyai kompetensi dalam melakukan pengelolaan data menggunakan HBase.

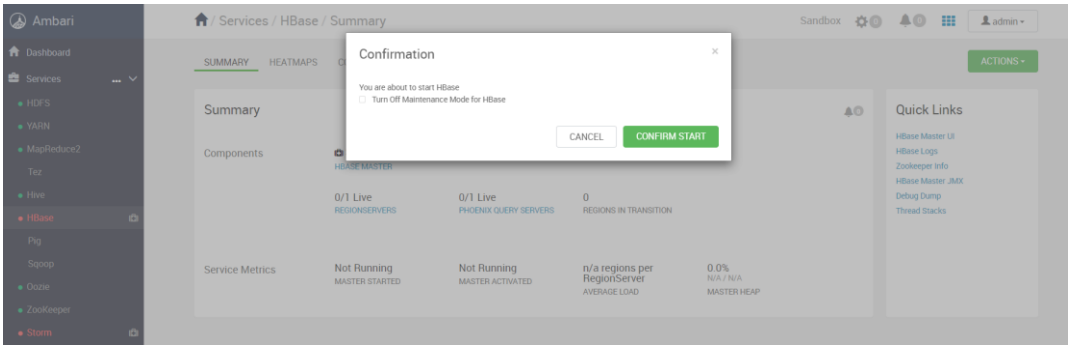
1.3. Material Praktikum

Persyaratan yang dibutuhkan untuk melakukan praktikum 10 yaitu:

1. HDP yang telah terinstal pada VirtualBox.
2. Ambari dapat diakses



3. Service HBase dalam keadaan hidup (*on*) dan dapat digunakan. Untuk menghemat resource, kita bisa matikan service yang tidak kita gunakan pada parktikum modul ini seperti Zeppelin, Kafka, Ranger, dan lain-lain.



4. MobaXterm untuk mengakses HBase shell.

1.4. Kegiatan Praktikum

Sebelum menggunakan HBase, kita dapat mengakses file-file konfigurasi HBase pada HDP di path **/etc/hbase/conf** (mungkin berbeda untuk HDP versi berbeda). Silakan buka (klik dua kali) menggunakan MobaXterm misalnya pada file **hbase-site.xml** untuk melihat (tidak perlu diedit) beberapa konfigurasi seperti **hbase.hregion.max.filesize**, dan lain-lain.

hbase-site.xml

```
    <name>hbase.coprocessor.regionserver.classes</name>
    <value></value>
  </property>

  <property>
    <name>hbase.defaults.for.version.skip</name>
    <value>true</value>
  </property>

  <property>
    <name>hbase.hregion.majorcompaction</name>
    <value>604800000</value>
  </property>

  <property>
    <name>hbase.hregion.majorcompaction.jitter</name>
    <value>0.50</value>
  </property>

  <property>
    <name>hbase.hregion.max.filesize</name>
    <value>10737418240</value>
  </property>

  <property>
    <name>hbase.hregion.memstore.block.multiplier</name>
    <value>4</value>
  </property>
```

A. Kelola Data dalam HBase

Pada bagian ini, kita akan mencoba membuat tabel-tabel di HBase dan melakukan query dari data di dalamnya.

1. Login ke dalam sistem HDP menggunakan MobaXterm dengan username: **root** dan password: **Tp4stis**
2. Masuk ke dalam HBase shell menggunakan perintah:

```
hbase shell
```

```
[root@sandbox-hdp ~]# hbase shell
HBase Shell
Use "help" to get list of supported commands.
Use "exit" to quit this interactive shell.
Version 2.0.0.3.0.1.0-187, re9fcf450949102de5069b257a6dee469b8f5aab3, Wed Sep 19 10:16:35 UTC 2018
Took 0.0035 seconds
hbase(main):001:0>
```

Untuk keluar dari shell, kita dapat menggunakan Ctrl+C atau perintah exit

```
hbase> exit
```

3. Setelah sukses masuk ke HBase shell, kita dapat melakukan eksekusi perintah umum, seperti:
   - Menampilkan semua tabel dalam HBase

```
hbase> list
```

```
hbase(main):001:0> list
TABLE
ATLAS_ENTITY_AUDIT_EVENTS
atlas_janus
2 row(s)
Took 1.1189 seconds
=> ["ATLAS_ENTITY_AUDIT_EVENTS", "atlas_janus"]
```

   - Menampilkan status dari HBase termasuk server yang *running* dalam sistem

```
hbase> status
```

```
hbase(main):002:0> status
1 active master, 0 backup masters, 1 servers, 0 dead, 4.0000 average load
Took 0.4279 seconds
```

- Menampilkan user yang sedang aktif

```
hbase> whoami
```

```
hbase(main):003:0> whoami
root (auth:SIMPLE)
    groups: root
Took 0.0908 seconds
```

4. Sebelum membuat table dan mengisinya dengan data, kita kan membuat namespace terlebih dahulu untuk mengelompokan tabel-tabel yang akan kita buat dalam praktikum modul ini. **Namespace** dapat dibuat dengan perintah:

```
hbase> create_namespace 'tpd_ns'
```

```
hbase(main):005:0> create_namespace 'tpd_ns'
Took 0.4044 seconds
```

5. Setelah namespace berhasil dibuat, kita dapat membuat **tabel** sebagai berikut:

Row key	personal data	professional data

dengan perintah:

`create '[table name]','[column family 1]','[column family 2]'`

```
hbase> create 'tpd_ns:employee','personal data','professional
data'
```

```
hbase(main):006:0> create 'tpd_ns:employee','personal data','professional data'
Created table tpd_ns:employee
Took 2.7527 seconds
⇒ Hbase::Table - tpd_ns:employee
```

Ketika kita eksekusi perintah **list** maka tabel employee akan ditampilkan dalam daftar.

```
hbase(main):007:0> list
TABLE
ATLAS_ENTITY_AUDIT_EVENTS
atlas_janus
tpd_ns:employee
3 row(s)
Took 0.0739 seconds
⇒ ["ATLAS_ENTITY_AUDIT_EVENTS", "atlas_janus", "tpd_ns:employee"]
```

6. Jika kita akan menghapus atau mengubah skema dari table, sebelumnya kita harus lakukan **disable** untuk menonaktifkan tabel tersebut dengan perintah:

```
hbase> disable 'tpd_ns:employee'
```

```
hbase(main):008:0> disable 'tpd_ns:employee'
Took 1.9006 seconds
```

Untuk memastikan apakah suatu table aktif atau tidak, kita dapat menggunakan perintah:

```
hbase> is_disabled 'tpd_ns:employee'
```

```
hbase(main):009:0> is_disabled 'tpd_ns:employee'
true
Took 0.0801 seconds
⇒ 1
```

Untuk mengaktifkan suatu tabel kita dapat menggunakan perintah:

```
hbase> enable 'tpd_ns:employee'
```

```
hbase(main):010:0> enable 'tpd_ns:employee'
Took 1.7369 seconds
```

7. Setelah tabel **employee** sukses dibuat dan dalam keadaan **enabled**, kita akan mengisinya dengan data sebagai berikut:

Row key	personal data		professional data	
empid	name	city	designation	salary
1	raju	hyderabad	manager	50,000
2	ravi	chennai	sr.engineer	30,000
3	rajesh	delhi	jr.engineer	25,000

dengan perintah:

`put '[table name]','rowkey','[colfamily:colname]','[value]'`

(data diisi untuk setiap **cell** satu per satu)

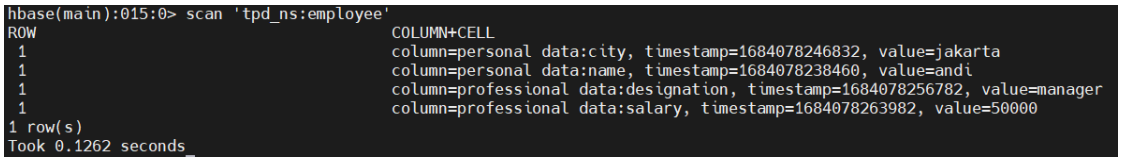
```
hbase> put 'tpd_ns:employee','1','personal data:name','andi'
hbase> put 'tpd_ns:employee','1','personal
data:city','jakarta'
hbase> put 'tpd_ns:employee','1','professional
data:designation','manager'
hbase> put 'tpd_ns:employee','1','professional
data:salary','50000'
```

```
hbase(main):011:0> put 'tpd_ns:employee','1','personal data:name','andi'
Took 0.3183 seconds
hbase(main):012:0> put 'tpd_ns:employee','1','personal data:city','jakarta'
Took 0.0543 seconds
hbase(main):013:0> put 'tpd_ns:employee','1','professional data:designation','manager'
Took 0.0356 seconds
hbase(main):014:0> put 'tpd_ns:employee','1','professional data:salary','50000'
Took 0.0141 seconds
```

8. Untuk melihat data di dalam tabel dapat menggunakan perintah sebagai berikut:

```
hbase> scan 'tpd_ns:employee'
```

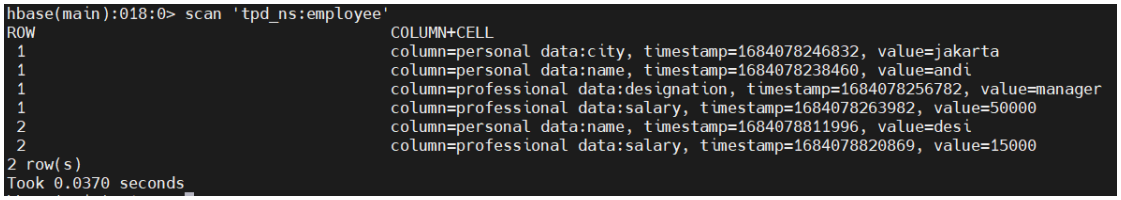
Data akan ditampilkan per-cell dalam tabel.



9. Misalkan untuk baris data ke-2, kita akan mengisikan dengan data yang berbeda skema column-nya.

```
hbase> put 'tpd_ns:employee','2','personal data:name','desi'
hbase> put 'tpd_ns:employee','2','professional
data:salary','15000'
```

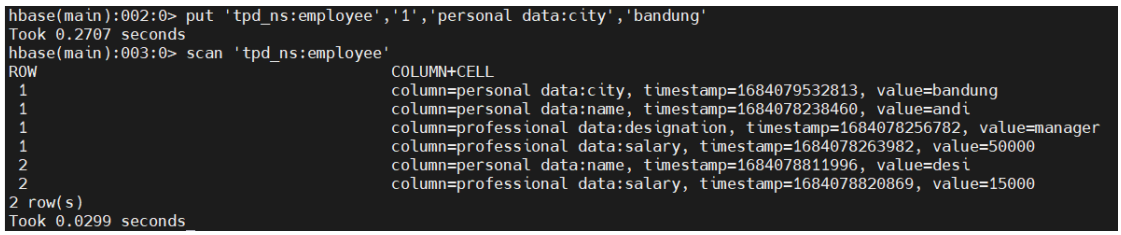
Tabel akan berisi nilai-nilai cell yang ditambahkan walaupun kolom tiap baris data berbeda.



10. Untuk melakukan update data di dalam tabel, dapat menggunakan perintah:

`put '[table name]','rowkey','[colfamily:colname]','[new value]'`

```
hbase> put 'tpd_ns:employee','1','personal
data:city','bandung'
```



11. Untuk melakukan query data dari tabel, kita dapat menggunakan perintah seperti:
    - Menampilkan baris/row tertentu (berdasarkan rowkey)

```
hbase> get 'tpd_ns:employee','1'
```

```
hbase(main):004:0> get 'tpd_ns:employee','1'
COLUMN                                  CELL
 personal data:city                     timestamp=1684079532813, value=bandung
 personal data:name                     timestamp=1684078238460, value=andi
 professional data:designation          timestamp=1684078256782, value=manager
 professional data:salary               timestamp=1684078263982, value=50000
1 row(s)
Took 0.1438 seconds
```

- Menampilkan baris dan kolom tertentu

```
hbase> get 'tpd_ns:employee','1', {COLUMN => 'professional
data:salary'}
```

```
hbase(main):005:0> get 'tpd_ns:employee','1', {COLUMN ⇒ 'professional data:salary'}
COLUMN                                  CELL
 professional data:salary               timestamp=1684078263982, value=50000
1 row(s)
Took 0.0570 seconds
```

- Menampilkan seluruh baris dengan kolom tertentu

```
hbase> scan 'tpd_ns:employee',{COLUMN => 'professional
data:designation'}
```

```
hbase(main):007:0> scan 'tpd_ns:employee',{COLUMN ⇒ 'professional data:designation'}
ROW                                     COLUMN+CELL
 1                                      column=professional data:designation, timestamp=1684078256782, value=manager
1 row(s)
Took 0.0333 seconds
```

- Menampilkan baris data (dari STARTROW sampai STOPROW) dengan kolom tertentu

```
hbase> scan 'tpd_ns:employee',{COLUMN => ['personal
data:name','professional data:designation'],STARTROW=>'1'}
hbase> scan 'tpd_ns:employee',{COLUMN => ['personal
data:name','professional
data:designation'],STARTROW=>'1',STOPROW=>'2'}
```

```
hbase(main):001:0> scan 'tpd_ns:employee',{COLUMN ⇒ ['personal data:name','professional data:designation'],STARTROW⇒'1'}
ROW                                     COLUMN+CELL
 1                                      column=personal data:name, timestamp=1684078238460, value=andi
 1                                      column=professional data:designation, timestamp=1684078256782, value=manager
 2                                      column=personal data:name, timestamp=1684078811996, value=desi
2 row(s)
Took 1.2380 seconds
```

Lihat perbedaan data hasil query dengan STOPROW:

```
hbase(main):001:0> scan 'tpd_ns:employee',{COLUMN ⇒ ['personal data:name','professional data:designation'],STARTROW⇒'1',STOPROW⇒'2'}
ROW                                     COLUMN+CELL
 1                                      column=personal data:name, timestamp=1684078238460, value=andi
 1                                      column=professional data:designation, timestamp=1684078256782, value=manager
1 row(s)
Took 1.2991 seconds
```

12. Untuk melakukan filter baris data seperti klausa WHERE pada SQL, kita perlu meng-import class **org.apache.hadoop.hbase.filter.SingleColumnValueFilter** sebagai berikut:

```
hbase> import
org.apache.hadoop.hbase.filter.SingleColumnValueFilter
hbase> import org.apache.hadoop.hbase.filter.CompareFilter
hbase> import org.apache.hadoop.hbase.filter.BinaryComparator
```

```
hbase(main):003:0> import org.apache.hadoop.hbase.filter.SingleColumnValueFilter
⇒ [Java::OrgApacheHadoopHbaseFilter::SingleColumnValueFilter]
hbase(main):004:0> import org.apache.hadoop.hbase.filter.CompareFilter
⇒ [Java::OrgApacheHadoopHbaseFilter::CompareFilter]
hbase(main):005:0> import org.apache.hadoop.hbase.filter.BinaryComparator
⇒ [Java::OrgApacheHadoopHbaseFilter::BinaryComparator]
hbase(main):006:0>
```

Kemudian, misalkan kita akan memfilter baris data dimana hanya akan menampilkan personal data:name == ‘desi’

```
hbase> scan 'tpd_ns:employee', {FILTER =>
SingleColumnValueFilter.new(Bytes.toBytes('personal data'),
Bytes.toBytes('name'),
CompareFilter::CompareOp.valueOf('EQUAL'),BinaryComparator.ne
w(Bytes.toBytes('desi')))}
```

Maka, baris dengan rowkey=2 akan ditampilkan.

```
hbase(main):006:0> scan 'tpd_ns:employee', {FILTER => SingleColumnValueFilter.new(Bytes.toBytes('personal data'), Bytes.toBytes('name'), CompareFilter::Compar
eOp.valueOf('EQUAL'),BinaryComparator.new(Bytes.toBytes('desi')))}
ROW                                   COLUMN+CELL
 2                                    column=personal data:name, timestamp=1684078811996, value=desi
 2                                    column=professional data:salary, timestamp=1684078820869, value=15000
1 row(s)
Took 1.3391 seconds
```

Operator perbandingan yang dapat digunakan sebagai berikut:

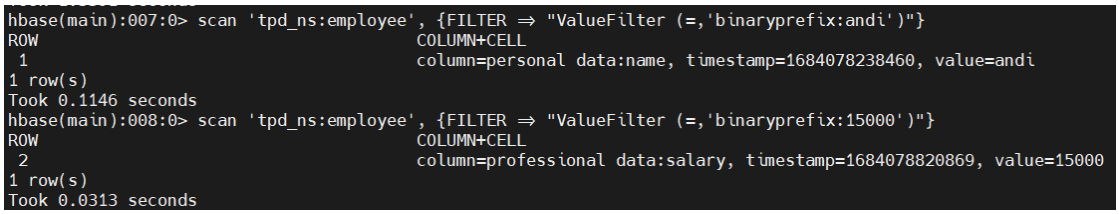
- EQUAL: sama dengan
- GREATER: lebih dari
- GREATER_OR_EQUAL: lebih dari sama dengan
- LESS: kurang dari
- LESS_OR_EQUAL: kurang dari sama dengan
- NOT_EQUAL: tidak sama dengan

Jika ingin mem-filter data dengan nilai tertentu untuk semua kolom yang match menggunakan perintah:

```
hbase> scan 'tpd_ns:employee', {FILTER => "ValueFilter
(=,'binaryprefix:andi')"}
```

```
hbase> scan 'tpd_ns:employee', {FILTER => "ValueFilter
(=,'binaryprefix:15000')"}
```

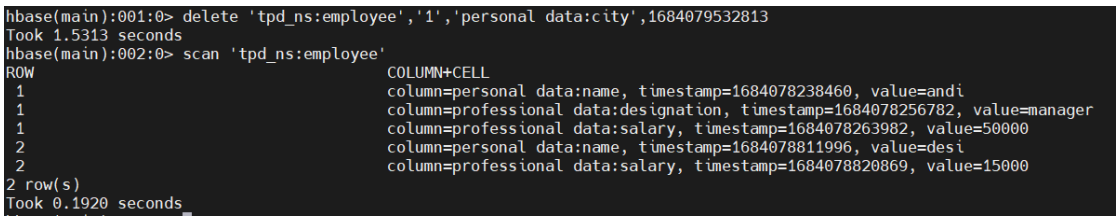
Akan ditampilkan hasil query data dengan nilai kolom apapun yang sesuai.



13. Perintah menghapus data di tabel dapat menggunakan perintah seperti:
    - Untuk menghapus cell data tertentu

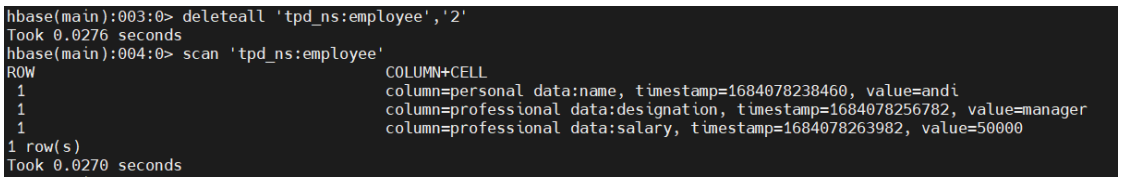
delete '[table name]','[rowkey]','[column name]','[time stamp]'

```
hbase> delete 'tpd_ns:employee','1','personal
data:city',1684079532813
```



- Untuk menghapus baris data tertentu semua kolom

```
hbase> deleteall 'tpd_ns:employee','2'
```



14. Meta table merupakan tabel khusus dalam HBase yang menyimpan metadata tentang semua Region yang ada dalam cluster HBase. Tabel ini bernama ‘hbase:meta’, sehingga untuk menampilkan data di dalamnya kita dapat menggunakan perintah:

```
hbase> scan 'hbase:meta'
```

```
hbase> scan 'hbase:meta',
{FILTER=>"PrefixFilter('tpd_ns:employee')"}
```

```
tpd_ns:employee                column=table:state, timestamp=1684084218791, value=\x08\x00
tpd_ns:employee,,1684077173148 column=info:regioninfo, timestamp=1684084218755, value={ENCODED => 76668ebf97a833ebf5bbf
.76668ebf97a833ebf5bbfefc37947 efc37947271, NAME => 'tpd_ns:employee,,1684077173148.76668ebf97a833ebf5bbfefc37947271.',
271.                            STARTKEY => '', ENDKEY => ''}
tpd_ns:employee,,1684077173148 column=info:seqnumDuringOpen, timestamp=1684084218755, value=\x00\x00\x00\x00\x00\x00\x0
.76668ebf97a833ebf5bbfefc37947 0"
271.
tpd_ns:employee,,1684077173148 column=info:server, timestamp=1684084218755, value=sandbox-hdp.hortonworks.com:16020
.76668ebf97a833ebf5bbfefc37947
271.
tpd_ns:employee,,1684077173148 column=info:serverstartcode, timestamp=1684084218755, value=1684073754328
.76668ebf97a833ebf5bbfefc37947
271.
tpd_ns:employee,,1684077173148 column=info:sn, timestamp=1684084218148, value=sandbox-hdp.hortonworks.com,16020,1684073
.76668ebf97a833ebf5bbfefc37947 754328
271.
tpd_ns:employee,,1684077173148 column=info:state, timestamp=1684084218755, value=OPEN
.76668ebf97a833ebf5bbfefc37947
271.
```

Kolom:

- **info:regioninfo** - berisi informasi Region termasuk didalamnya table name, start key, dan end key
- **info:server** - berisi informasi RegionServer

B. Snapshots dalam HBase

Snapshot table di HBase adalah fitur yang memungkinkan untuk membuat salinan "snapshot" dari satu atau beberapa tabel HBase pada titik waktu tertentu berisi data tabel dan skemanya. Snapshot dapat digunakan untuk berbagai tujuan, seperti backup, pemulihan data, analisis historis, atau pengujian.

1. Untuk membuat snapshot suatu tabel di suatu waktu tertentu dilakukan dengan perintah (nama snapshot bebas - silakan diganti tanggal pembuatan snapshot):

```
hbase> snapshot 'tpd_ns:employee', 'pegawaiData-15052023'
```

```
hbase(main):017:0> snapshot 'tpd_ns:employee','pegawaiData-15052023'
Took 5.3687 seconds
```

2. Untuk menampilkan semua snapshot di sistem HBase dilakukan dengan perintah:

```
hbase> list_snapshots
```

```
hbase(main):018:0> list_snapshots
SNAPSHOT                                TABLE + CREATION TIME
 pegawaiData-15052023                   tpd_ns:employee (2023-05-14 16:54:02 UTC)
1 row(s)
Took 0.1063 seconds
=> ["pegawaiData-15052023"]
```

3. Untuk membuat suatu tabel baru dari suatu snapshot dapat dilakukan menggunakan perintah:

```
hbase> clone_snapshot 'pegawaiData-15052023',
'tpd_ns:new_employee'
```

```
hbase(main):019:0> clone_snapshot 'pegawaiData-15052023','tpd_ns:new_employee'
Took 5.2583 seconds
hbase(main):020:0> list
TABLE
ATLAS_ENTITY_AUDIT_EVENTS
atlas_janus
tpd_ns:employee
tpd_ns:new_employee
4 row(s)
Took 0.1751 seconds
=> ["ATLAS_ENTITY_AUDIT_EVENTS", "atlas_janus", "tpd_ns:employee", "tpd_ns:new_employee"]
```

4. Misalkan tabel employee (yang sudah kita ambil snapshot-nya) kita lakukan penghapusan data rowkey=3 dari:

```
hbase(main):021:0> scan 'tpd_ns:employee'
ROW                                   COLUMN+CELL
 1                                    column=personal data:name, timestamp=1684078238460, value=andi
 1                                    column=professional data:designation, timestamp=1684078256782, value=manager
 1                                    column=professional data:salary, timestamp=1684078263982, value=50000
 2                                    column=personal data:name, timestamp=1684083120364, value=budi
 2                                    column=professional data:salary, timestamp=1684083043799, value=15000
 3                                    column=personal data:city, timestamp=1684083172044, value=makasar
 3                                    column=personal data:name, timestamp=1684083163191, value=kaka
 3                                    column=professional data:designation, timestamp=1684083189209, value=programmer
 3                                    column=professional data:salary, timestamp=1684083179639, value=23000
3 row(s)
Took 0.0684 seconds
```

Menjadi:

```
hbase(main):023:0> scan 'tpd_ns:employee'
ROW                                   COLUMN+CELL
 1                                    column=personal data:name, timestamp=1684078238460, value=andi
 1                                    column=professional data:designation, timestamp=1684078256782, value=manager
 1                                    column=professional data:salary, timestamp=1684078263982, value=50000
 2                                    column=personal data:name, timestamp=1684083120364, value=budi
 2                                    column=professional data:salary, timestamp=1684083043799, value=15000
2 row(s)
Took 0.0581 seconds
```

Ternyata, penghapusan baris tersebut merupakan kesalahan dan kita ingin mengembalikan data ke keadaan dimana snapshot diambil. Kita dapat melakukan restore snapshot ke tabel employee sebagai berikut:

```
hbase> disable 'tpd_ns:employee'
hbase> restore_snapshot 'pegawaiData-15052023'
```

```
hbase(main):024:0> disable 'tpd_ns:employee'
Took 4.7321 seconds
hbase(main):025:0> restore_snapshot 'pegawaiData-15052023'
Took 4.0226 seconds
hbase(main):026:0> enable 'tpd_ns:employee'
Took 1.5512 seconds
hbase(main):027:0> scan 'tpd_ns:employee'
ROW                                   COLUMN+CELL
 1                                    column=personal data:name, timestamp=1684078238460, value=andi
 1                                    column=professional data:designation, timestamp=1684078256782, value=manager
 1                                    column=professional data:salary, timestamp=1684078263982, value=50000
 2                                    column=personal data:name, timestamp=1684083120364, value=budi
 2                                    column=professional data:salary, timestamp=1684083043799, value=15000
 3                                    column=personal data:city, timestamp=1684083172044, value=makasar
 3                                    column=personal data:name, timestamp=1684083163191, value=kaka
 3                                    column=professional data:designation, timestamp=1684083189209, value=programmer
 3                                    column=professional data:salary, timestamp=1684083179639, value=23000
3 row(s)
Took 0.0393 seconds
```

5. Untuk menghapus snapshot dapat menggunakan perintah:

```
hbase> delete_snapshot 'pegawaiData-15052023'
```

1.5. Penugasan

Kerjakan sesuai dengan yang dijelaskan pada bagian Kegiatan Praktikum.

1. Bandingkan performa read/write dengan Hive di praktikum modul sebelumnya, manakah yang relative lebih cepat?
2. Buat sebuah tabel **UserProfiles** dari suatu data sebagai berikut:

Rowkey	details			activity		
	location	name	age	lastlogin	posts	follower
UserID001		John Smith	32		25	500
UserID002	New York	Sarah Johnson	28	2023-05-12	50	1000
UserID003	Los Angeles	Michael Anderson	45	2023-05-13	10	250

   Dari tabel di atas, apa perintah untuk menampilkan:
   a. Nama user yang berlokasi di New York
   b. Nama dan last login user yang melakukan posting lebih dari 20 kali
3. Hasil pekerjaan praktikum berupa dokumentasi:
   a. Screenshot tabel employee dan snapshot yang dibuat pada kegiatan praktikum
   b. Screenshot tabel, perintah, dan hasil query penugasan nomor 2