UJIAN AKHIR SEMESTER GENAP T.A. 2022/2023

MATA KULIAH	= Teknologi Perekayasaan Data
TINGKAT	= III - D4 SI
DOSEN	= Tim Dosen
HARI, TANGGAL	= Kamis, 22 Juni 2023
WAKTU SIFAT UJIAN	= Tutup Buku

A. Pilihan Ganda

1. Diantara format file dibawah ini, yang paling efisien dalam hal kompresi dan penghematan ruang penyimpanan di Hadoop adalah…
   a. CSV
   b. Avro
   c. Parquet
   d. JSON
2. Untuk dapat melakukan incremental load menggunakan sqoop, pilihan (*option*) yang digunakan dalam command **sqoop import** adalah…
   a. --incremental, --exec, --check
   b. --incremental, --last-value, --check-column
   c. --incremental, --check-value, --incremental-column
   d. --incremental--load, --last-value, --check-column
3. Command **sqoop eval** pada Sqoop dapat digunakan untuk...
   a. Melakukan load data pada HDFS
   b. Preview data pada HDFS
   c. Melihat list tabel yang ada pada sumber data
   d. Melakukan query baik DDL maupun DML pada sumber data
4. Komponen Hive yang berperan sebagai framework untuk cross language services adalah
   a. Drive
   b. CLI
   c. Thrift Server
   d. Metastore
5. Pernyataan berikut ini yang benar tentang Hive Metastore adalah
   a. Pusat penyimpanan data dalam basis data baik dalam bentuk tabel yang berada di Hadoop
   b. Pusat penyimpanan metadata untuk tabel dan partisi Hive dalam basis data relasional, dan memberikan client akses ke informasi ini menggunakan API layanan metastore

c. Pusat penyimpanan skema tabel yang terletak di hadoop repositori data yang bisa diakses dengan mudah
d. Proses menjalankan data dan kueri data SQL yang dapat dijalankan di hadoop ekosistem.

6. Dalam Hive, kita dapat membuat tabel dengan command sebagai berikut.

```
CREATE TABLE sales1…

CREATE EXTERNAL TABLE sales2…

Perbedaan dari kedua tabel tersebut adalah
```

a. sales1 adalah tabel yang dapat diakses secara eksternal oleh aplikasi lain di luar Apache Hive, sedangkan sales2 adalah tabel yang hanya dapat diakses oleh Apache Hive itu sendiri
b. sales1 adalah tabel yang memiliki struktur skema yang ketat, sedangkan sales2 adalah tabel yang memungkinkan skema yang fleksibel
c. sales1 adalah tabel yang disimpan di dalam basis data Hive secara terorganisir baik data dan metadata, sedangkan sales2 adalah tabel yang hanya disimpan meta datanya tanpa menyimpan data fisik
d. Tidak ada perbedaan fungsional pada dua tabel tersebut karena istilah table pada sales1 dan sales2 dapat digunakan secara bergantian untuk menggambarkan tabel-tabel yang dikelola oleh Hive

7. Berikut ini yang termasuk perintah Data Definition Language pada HiveQL, kecuali
a. LOAD TABLE
b. CREATE TABLE
c. SHOW TABLE
d. DESCRIBE

8. Model data yang digunakan oleh Apache HBase adalah
a. Graph
b. Key-value
c. Document
d. Column-Family

9. Berikut ini merupakan perbedaan Hive dan HBase adalah
a. Hive menyediakan API untuk membaca dan menulis data menggunakan operasi CRUD, sedangkan HBase dirancang untuk query data menggunakan bahasa HiveQL
b. Hive cenderung lebih cocok untuk pemrosesan batch, sedangkan HBase dirancang untuk pemrosesan data yang membutuhkan akses baca/tulis yang cepat pada level baris
c. Hive lebih sesuai untuk aplikasi yang memerlukan akses langsung ke data, pemrosesan transaksi dengan kebutuhan respons real-time, sedangkan HBase lebih cocok untuk analisis data yang berbasis query untuk pemrosesan batch
d. Hive dan HBase mempunyai tipe pemrosesan data yang sama

10. Pernyataan berikut yang benar tentang HBase adalah
1) HBase memanfaatkan MapReduce untuk memproses data dalam Hadoop
2) Region split pada HBase membagi data berdasarkan rentang column-family
3) HFile merupakan format file dalam HBase untuk menyimpan data dalam Region

4) Random access pada HBase memungkinkan karena indeks Row Key pada setiap baris data
5) Perintah select digunakan untuk membaca data pada HBase, sama dengan perintah Hive

a. 1 dan 2
b. 2 dan 3
c. 3 dan 4
d. 4 dan 5

11. Diketahui suatu tabel HBase bernama **produk** sebagai berikut.

Row Key	Info		
	Nama	Harga	Stok
1	Mouse	100,000	50
2	Keyboard	230,000	30
3	Monitor	600,000	100

Perintah HBase yang digunakan untuk mengambil data dengan Row Key "3" adalah

a. SCAN ‘produk’, ‘3’
b. GET ‘produk’, ‘3’
c. SELECT ‘produk’, ‘3’
d. FETCH ‘produk’, ‘3’

12. Urutan proses yang dilakukan oleh Pig Engine adalah

a. parse - compile - optimize - plan
b. parse - compile - plan - execute
c. parse - optimize - compile - execute
d. parse - optimize - compile - plan

13. Layanan yang menjadi solusi untuk membangun alur data yang dapat menangani aliran data streaming dalam jumlah besar secara efisien dan handal adalah

a. Pig
b. Sqoop
c. Hive
d. Kafka

14. Diketahui suatu data file CSV akan diproses menggunakan Apache Pig sebagai berikut

```
students = LOAD ‘students.csv’ USING PigStorage(‘,’) as
(fname: chararray, lname: chararray, age: int, grade: int);
```

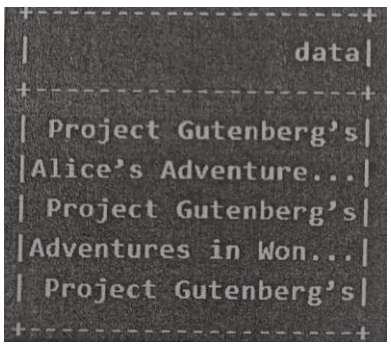
Pig Script yang digunakan untuk mengambil data siswa dengan usia di atas 20 tahun adalah

a. students_20 = FOREACH students GENERATE age > 20;

b. students_20 = SELECT students WHERE age > 20;
c. students_20 = FILTER students BY age > 20;
d. students_20 = SPLIT students INTO age_gt_20 IF age > 20, age_lte 20 IF age <= 20;

15. Pernyataan berikut yang benar tentang message dalam Apache Kafka adalah
    a. Sebuah message dalam sebuah topik dikirimkan ke semua partisi dalam topik tersebut secara paralel
    b. Sebuah message dalam sebuah topik dikirimkan ke salah satu partisi tertentu dalam topik tersebut
    c. Offset sebuah message di dalam sebuah partisi Kafka digunakan untuk mengatur kecepatan produksi message dalam partisi tersebut
    d. Offset sebuah message merupakan kunci yang digunakan untuk mengenkripsi message di topik Kafka
16. Berikut ini merupakan struktur data dasar Spark dan abstraksi data utama pada Apache Spark dan Spark Core adalah
    a. Dataframe
    b. Linked List
    c. Hash Table
    d. Resilient Distributed Dataset
17. Diketahui Data sebagai berikut.

Input Data:



Output:



Jenis transformasi di Spark yang berfungsi untuk menghasilkan output di atas adalah
    a. collect()
    b. map()
    c. filter()
    d. flatMap()
18. Operasi yang digunakan pada dataframe Spark untuk melakukan modifikasi pada konten data adalah
    a. groupBy
    b. select
    c. withColumn
    d. filter
19. Ketika sebuah transformasi diterapkan pada Immutable RDD dalam Apache Spark, apa yang sebenarnya terjadi?
    a. RDD awal diubah menjadi RDD baru yang sepenuhnya independen
    b. Data dalam RDD awal diubah secara langsung tanpa membuat RDD baru

c. RDD baru dibuat yang hanya menyimpan perbedaan dengan RDD awal
d. Transformasi dieksekusi pada RDD awal secara berurutan satu per satu

20. Processing tool yang terdapat di Hadoop dan hanya terbatas untuk menangani structured data adalah
    a. Spark
    b. Hive
    c. Pig
    d. Map Reduce
21. Tahapan yang dilakukan dalam proses menstrukturkan data tidak terstruktur pada data Text, kecuali
    a. Flatering Flatmap
    b. Text Extraction
    c. Parsing/Tokenization
    d. Phrase Recognition
22. Berikut ini pernyataan yang benar tentang pemrosesan data semi-structured pada Data Lake Hadoop adalah
    a. Penentuan skema data dilakukan ketika data disimpan dalam Data Lake
    b. Data dapat dikonversi ke dalam format Avro untuk penyesuaian skema data ketika data dibaca
    c. Data semi-structured dapat diproses sebagai tabel Hive untuk menjamin skema data yang fleksibel di Data Lake
    d. Skema tidak relevan dalam pemrosesan data semi-structured pada Data Lake
23. Metode untuk mengirimkan suatu file dari suatu sistem ke server penyimpanan, melalui konektivitas berbasis IP sebagai bagian dari layanan on-demand adalah dari layanan cloud computing...
    a. Software-as-a-service
    b. Platform-as-a-service
    c. Infrastructure-as-a-service
    d. Cloud-as-n-service
24. Apa yang dimaksud dengan hypervisor dalam virtualisasi Cloud Computing?
    a. Alat yang mengatur kecepatan koneksi internet di Cloud
    b. Komponen perangkat keras yang memastikan ketersediaan Cloud secara terus-menerus
    c. Perangkat lunak yang mengelola mesin virtual dan alokasi sumber daya
    d. Teknologi enkripsi yang melindungi data saat transit di Cloud
25. Tipe cloud computing yang memungkinkan pengguna tidak perlu melakukan pengelolaan sendiri dan hanya membayar sesuai dengan pemakaian adalah
    a. laas
    b. SaaS
    c. PanS
    d. Virtualization

B. Essai

1. Sebutkan 5 command Sqoop disertai penjelasan dan contoh penggunaan command tersebut!
2. Diketahui suatu tabel pada Apache Hive sebagai berikut.

Tabel A		
ID	Nama	Usia
1	John	25
2	Sarah	28
3	Michael	30
4	Emma	32
5	David	37
6	Lisa	31
7	Andrew	29
8	Emily	26
9	James	33
10	Olivia	24

Tabel B		
ID	Kota	Gaji
1	Jakarta	5000
2	Surabaya	4500
3	Bandung	4000
4	Medan	4200
5	Semarang	4800
6	Makassar	4100
7	Palembang	3900
8	Denpasar	4600
9	Malang	4300
10	Yogyakarta	5200

Bagaimana query menggunakan HiveQL untuk perintah:

a. Menggabungkan Tabel A dan Tabel B berdasarkan kolom ID
b. Menampilkan nama dan gaji pegawai yang berumur dibawah 30 tahun dan berada di kota Jakarta

3. Diketahui suatu pemrosesan real-time data pada Apache Kafka menggunakan 3 Broker/Kafka Server dimulai dengan command sebagai berikut:

```
kafka-topics.sh --create --zookeeper <zookeeper_host>:
<zookeeper_port> --replication-factor 1 --partitions 3 --
topic clicks
```

a. Apakah nama topic dan berapa jumlah partisi untuk topic tersebut?

b. Gambarkan secara jelas dan sederhana hubungan antara Producer, Broker, Topic, Partition, dan Consumer pada kasus di atas! (perhatikan jumlah tiap komponen)
c. Jelaskan secara singkat model komunikasi yang digunakan dalam aliran data real-time pada Apache Kafka!

4. Jelaskan perbedaan antara Spark dan MapReduce!
5. Jelaskan apakah yang dimaksud dengan Google Cloud Platform dan sebutkan fitur-fitur yang disediakan oleh GCP?